



화물 기사 자동 매칭 시스템 (XGBoost 기반 예측 모델)

삼성아카데미 데이터 분석과정: 이제우



목차



1. 개요
2. 데이터 구조
3. 전처리 과정
4. 모델 구조 및 파라미터
5. 모델 학습 결과
6. 매칭결과
7. 원인분석
8. 향후계획
9. 출처





1. 개요



- 목표: 실제 운송 데이터 기반 기사-화물 자동 매칭 모델 구축
- 모델 목적: 각 화물에 대해 가장 적합한 기사예측





2. 데이터 구조



중국 5개지역의 배송 데이터

2개의 csv파일

- trajectory: 51,122,257행, 5열 → 기사 GPS 궤적 데이터
- pickup: 2,348,912행, 24열 → 화물·배차·픽업 정보

trajectory 주요 컬럼: got_gps_lng, got_gps_lat, accept_gps_lng, accept_gps_lat

pickup 주요 컬럼: delivery_user_id, from_dipan_id, from_city_name





3. 전처리 과정



1. 중복 제거: delivery_user_id + gps_time 기준 0건
2. 불균형 처리: 거리, 시간상 상위 10% 기사 데이터 집중:
→ groupby().sample() + scale_pos_weight=3
3. GPS 병합 및 결측 제거: merge_asof() + notnull() → 결측치 0, 239,618건 유지

```
pickup_with_driver = pd.merge_asof(
    df_pick,
    df_traj,
    left_on='accept_time',
    right_on='gps_time',
    by='delivery_user_id', # 같은 운전자 기준
    direction='nearest'
)
```

4. 파생 피처 생성:
distance_km (위도, 경도)
hour, weekday (시간/요일)
rank (화물 내 거리순)
label (실제 매칭=1, 비매칭=0)

```
pickup_only.shape

(239618, 15)

# 결손치 우리가 필요한 필드가 null인지 확인
null_counts_1 = pickup_only.isnull().sum()
null_counts_1

from_dipan_id    0
from_city_name   0
delivery_user_id  0
accept_time      0
book_start_time  0
poi_lng          0
poi_lat          0
aoi_id           0
typecode         0
ds_x             0
delivery_user_name 0
ds_y             0
gps_time         0
lat              0
lng              0
dtype: int64
```



4. 모델 구조 및 파라미터



모델명: XGBoostClassifier

Objective: binary:logistic

Eval_metric: AUC

학습 데이터: train.csv (1,064,700행)

주요 파라미터:

max_depth = 8

learning_rate = 0.1

n_estimators = 200

subsample = 0.8

colsample_bytree = 0.8


scale_pos_weight = 3

Train:Validation = 8:2 / Early stopping: 20 rounds



5. 모델 학습 결과


XGBoost 모델 성능 지표



Validation Accuracy: 0.9949 / AUC: 0.9998

○○○ 6. 매칭결과 (예측 및 배차) ○○○

화물-기사 자동매칭 (Leaflet / OpenStreetMap) 데이터 불러오기 선택 화물 자동매칭 맵기호: 227ae63c3e3 * API: /api/orders, /api/drivers, /api/match, /api/drivers_near



TOP1 거리: 5.67 km - 모달: 0.781 - 중점: 0.347
TOP2 거리: 5.50 km - 모달: 0.644 - 중점: 0.306
TOP3 거리: 2.61 km - 모달: 0.192 - 중점: 0.242

파란점: 화물 위치

초록점: 1순위 기사

노란점: 2순위 기사

주황점: 3순위 기사

빨간점: 근처의 다른 기사



7. 원인분석



- 데이터 구조 착시: 과거 배차 기록 복제 → 실가용성 반영 X
- 피처 부족(단순 구조): 거리/시간 중심 → 실제 운행 제약(차종, 오프라인 상태 등) 미포함
- 데이터 불균형: 일부 기사에 label=1(매치) 집중 → 확률 쏠림 현상
- 매칭 로직 한계 (idxmax 단일 선택): TOP1만 강제 선택, TOP2·TOP3의 상대 확률과 거리 보정이 무시되어 비현실적 배차 발생





8. 향후계획



- 1. 피처 확장: 기사 상태, 차량 종류, 도로혼잡도 별점 등 반영
- 2. 확률 정규화: Softmax 기반 상대확률 비교
- 3. 불균형 개선: SMOTE / Class Weight / GroupKFold
- 4. 모델 고도화: XGBRanker, LightGBM Ranker, CatBoost 적용
- 5. 실시간 피드백: 실제 매칭 성공/실패 로그로 재학습
- 6. 결제시스템 도입





9. 출처



Hugging Face: <https://huggingface.co/datasets/Cainiao-AI/LaDe/tree/main> (Cainiao-AI/LaDe)





- End -

